

召回思路


主要思路

 通过ItemCF和DSSM双塔模型进行多路召回，通过融合多路召回分选取Top50个Item作为召回结果；

多路召回

ItemCF召回

- ItemCF 利用用户的历史点击序列，通过统计 item 与 item 的共现（共同出现在一个用户序列中）的频次计算余弦相似度
- 为了提升质量，引入了间隔时间、位置距离加权和用户活跃度抑制机制；
- 对于每个用户，根据其历史点击的每篇文章，召回与其相似性最高的N（TopN） 文章，并合并去重后排序（最大是 $M \times N$ ，M为用户序列长度，且没有重复时达到最大），得到最终 TopK 推荐结果。



 强关联**最近点击行为**优化：仅使用最近点击的两篇文章进行I2I召回。（符合新闻推荐场景的短期时效性）

item相似性矩阵计算

- 基于用户点击序列统计item之间**共现频次**
 - 如item1和item2共同出现在了某个用户点击序列中，则分数+1
 - $Score[i][j] + = 1$
- **优化1：引入间隔距离**
 - 统计item1和item2在同一点击序列权的间隔距离GAP，对分数按照以下公式加权
 - $coef_1 = 0.9^{|GAP|-1}$
- **优化2：引入用户活跃度抑制**
 - 用户越活跃，说明该用户有大量点击行为，那么item之间同时出现在该用户序列的概率变大，但原因可能**并不是item之间具有相似性**，只是当前用户活跃度高，因此按照以下公式加权抑制
 - $coef_2 = \frac{1}{\log(UserClickCount) + 1}$
- **优化3：引入正逆序权重**
 - 因为位置后的点击行为是受到位置前的影响的，因为推荐的进行也是基于已发生的点击行为，因此在统计相似度时考虑item出现的顺序。若是正序，则权重为1，若是逆序则是0.7
 - 如在某一序列中计算itemi与其他item的相似度时，itemj(j>i, j比i晚点击)，则权重乘1，itemk(k<i)，则权重乘0.7。
 - $coef_3$
 - 结合代码看能理解一些

$$sim[i][j] + = coef_1 * coef_2 * coef_3$$

分数召回

- 遍历每个用户的点击序列，从**点击过的item出发**，根据**相似性矩阵**，找topN个最相似的结果作为初步推荐，如序列长度为K（共点击K个item），则**最多可找到NK个item**，但实际可能存在重复，因此叠加相似性分数。然后再排序截断前topk个作为最终推荐结果。

$$Score_i = \sum_j sim[j][i], (i \text{ 为被召回 item}, j \text{ 为点击过的 item})$$

- **优化1：基于用户点击item的位置加权**

- 若 $item_j$ 为当前用户最新的点击，则以 $item_j$ 出发找到的topN个最相似的item更可能成为最终的推荐结果，因此提高权重。按照以下公式加权
- $coef_{1j} = 0.9^{len(seq)-loc_j}$
- **优化2：强关联最近点击行为优化**
 - 考虑**新闻推荐短时效性**的特点，仅使用用户最近点击的**两篇**文章进行召回。
- **优化3：引入item创建时间权重**
 - 创建时间间隔相近的item相关概率>创建时间间隔较远的item相关概率
 - $coef_{2j} = exp(0.8^{GAP_{T_{create}}})$

$$Score_i = \sum_j sim[j][i] * coef_{1j} * coef_{2j}$$

DSSM双塔召回

- DSSM 采用**解耦的双塔架构**，分为 **User Tower** 与 **Item Tower**，实现用户与物料特征的独立向量表征。
- 输入端分别将用户侧特征（画像、行为序列）与物料侧特征（ID、类目属性）送入各自的塔（深度神经网络）中，经过多层非线性变换，降维输出为同一维度的**稠密特征向量**。
- 模型通过海量样本进行端到端训练，优化网络参数。最终使得通过各自塔计算得到的**用户向量与物料向量的点积**作为当前用户召回当前物料的分数，最终通过**得分排序**即为召回结果。

这里做了一点小优化，将序列特征按照点击的位置加权融合，最近点击的item权重高

特征选择

用户：ID、历史点击行为序列，使用手机的操作系统环境等

物品：文章字数、文章类别、文章创建时间，ID

离散特征：构建一一对应的embedding，参与模型训练


连续特征：归一化（也可以等频分桶后化为离散特征，再embedding，这里选择的是归一化）

总特征：拼接离散特征的embedding和归一化连续数值

模型结构


- 用户塔接收用户特征输入，通过神经网络的层级映射与特征融合，将高维离散的用户特征转化为低维稠密的**用户嵌入向量（u）**，该向量蕴含用户核心兴趣与行为模式的抽象表示；

- 物品塔则以物品特征为输入，经同等逻辑的特征处理流程，生成浓缩物品核心属性的**物品嵌入向量** (v)
- 在完成双塔各自的特征编码后，模型通过计算用户嵌入向量 u 与物品嵌入向量 v 的**余弦相似度**，量化二者的语义匹配程度，该相似度值即为用户对当前物品的点击分数的预测结果。



正负样本构建

- 正样本**：用户真实点击行为就是正样本，即每个 **(用户，物品)** 对应实际发生的交互行为，构成**正样本对**
- 负样本**：基于**批次内 (Batch) 负采样**构建**负样本对**
 - 训练时先把**正样本对**批量采样，若设定批次大小 (batch size) 为 256，则单批次包含 256 个独立**正样本对**
 - 负样本采用批量内负采样策略就是，对于一个用户，在批次内，除了其点击的item外，其余的 255 个item都作为当前用户的负样本。即某用户 (如用户 1) 点击的正样本物品 (如 Item1) 外，同批次中其他 255 个用户的正样本物品 (如 Item2~Item256) 与其组成负样本对
 - 这样做的理由是：样本通过随机筛选的方式构建成一个批次，且用户点击行为与海量的item相比是十分稀疏的，因此这种通过随机筛选得到的item，大概率与该用户未发生交互，因此直接将这物品作为该用户的负样本，每个用户对应 255 个批量内负样本。



损失函数

- 基于上述正负样本采样后，每个用户都有一个正样本对和255 (bs-1)个负样本对
- 模型训练时，用户和item特征先分别通过用户塔与物品塔进行独立编码，生成浓缩后能够表征各自语义信息的**用户和item的嵌入向量**
- L2归一化后再计算嵌入向量间的内积（等价于**余弦相似度**）作为匹配分数；这时候就有1个正样本对的匹配分数和255个负样本对的匹配分数
- 学习的目标是为了提高正样本对之间的匹配分数和拉低负样本对之间的匹配分数，因此基于**InfoNCE 损失函数**进行梯度优化
- 通过 **softmax 函数**将当前用户与批次内所有物品的匹配分数转化为概率分布，再以**交叉熵损失**衡量正样本匹配概率与理想分布的差异，最终通过反向传播更新双塔网络参数，实现模型优化。

$$\mathcal{L}_{\text{InfoNCE}} = -\frac{1}{N} \sum_{i=1}^N \log \frac{\exp(\text{sim}(u_i, v_i)/\tau)}{\sum_{j=1}^N \exp(\text{sim}(u_i, v_j)/\tau)}$$

N ：批大小 (batch size)

u_i ：第 i 个用户的嵌入向量


v_i ：第 i 个正样本物品的嵌入向量

$sim(\cdot, \cdot)$ ：余弦相似度（归一化后即为内积 $u^T v$ ）

τ ：温度系数（temperature）

推理

- 训练完成的双塔模型可实现用户塔与物品塔的**解耦部署**，两塔各自输出能够精准表征用户核心语义、物品核心属性的低维稠密嵌入向量。
- 离线阶段，将物品库中全部物品的特征输入独立的物品塔，完成全量物品嵌入向量的生成与存储，并基于 **Faiss 库** 为该批嵌入向量构建高效的**向量检索索引**
- 线上推理阶段，实时获取用户特征并输入独立的用户塔生成用户嵌入向量，将该向量在 Faiss 索引库中执行内积相似度检索，选取相似度得分 Top-K 的物品作为最终召回结果。



本次竞赛无线上推理数据，整体召回流程均通过离线方式完成。针对需要召回的用户，基于其特征批量输入用户塔生成对应嵌入向量（用户间计算相互独立），随后将该批向量在已构建的 Faiss 物品嵌入索引库中执行内积相似度检索，选取相似度最高的 Top-K 个物品，作为各测试用户的最终离线召回结果。

多路融合

将多路召回结果（ItemCF + DSSM）通过**加权投票融合**合并：

1. **分数归一化**：对每个召回通道的分数独立进行Min-Max归一化（映射到 $[0.1, 1.0]$ ），再乘以该通道预设的权重系数，权重系数是通过枚举测试得到一个最优的（DSSM:0.55, ItemCF:0.45）。

2. **投票聚合**：按 `(user_id, article_id)` 分组，统计每个候选Item被多少个通道召回（`n_votes`），以及加权分数之和（`sim_score`）。
3. **排序截断**：按 `n_votes` 降序、`sim_score` 降序排列，被多个通道同时召回的Item优先级更高，每个用户取Top-50。
4. **热门Item补全**：若某用户召回不足50个，用全局热门Item（按点击次数排序Top-350）补全。