

真实面试题

业务背景理解

1. 用户量多大？item库有多少？都有什么特征？目标是做一个什么任务？评估指标是什么？

是什么回答什么就可以，详情见项目介绍。

2. 新闻推荐和其他场景的区别？

- 时效性强，内容快速迭代
 - 新闻内容生命周期非常短，通常在几小时到几天内就失效；
 - 推荐系统需要快速感知最新热点、突发事件（如地震、政治变动）；
- 用户兴趣变化快，短期兴趣主导行为
 - 用户在看新闻时通常是“以主题为驱动”，关注某一事件、话题；
 - 兴趣具有强烈的短期性和上下文依赖，如用户刚看完“地震新闻”，下一个点击大概率仍与灾害有关；
- 冷启动严重，长尾问题突出
 - 新闻内容每天都在刷新，大量新内容没有用户交互记录；
 - 常规的协同过滤或基于行为的模型在新内容上难以工作；

样本与特征工程

3. 有使用lightgbm进行特征筛选吗？

如果简历没有提到有用过lightGBM这样的模型，一般不会提到这种树模型相关的问题，如果有问特征筛选的策略这里是一个回答的方向。

答：有使用。初期还加入了用户点击的上下文特征，如用户点击的环境、操作系统、点击来源等。LightGBM训练完后输出的重要性表明，上下文特征重要性几乎为零因此进行了剔除。但是效果变化不大，计算量减小了一些。

4. 为什么要做负采样？负采样的方法有哪些？batch内负采样存在什么优缺点？怎么解决？

(1) 为什么要做负采样

出于计算性能的考量，在百万级甚至更大的Item库中，如果要所有没被点击过的item作为负样本来计算Softmax，耗费的算力是不现实的。负采样把海量的多分类问题转化为了极小范围内的计算，大幅降低了训练开销。

(2) 负采样方法

- **全局随机负采样**：直接在item库中等权采样
- **基于流行度采样**：依据物品的热度分布抽取，常常用来压制热门物品的推荐倾斜。
- **Batch 内负采样**：直接复用同一个 Batch 里面其他人的正样本作为当前用户的负样本。

(3) Batch内采样优缺点

优点：

- 在一个批次内的user和item输出的向量后，仅需要一次矩阵内积，就可以把批次内每个用户与所有正负样本进行向量内积得到一个兴趣分数，然后可以直接进行softmax然后计算交叉熵损失
- Batch内负采样结合Softmax和交叉熵损失计算，相比于传统二分类（如BCE）对样本进行独立、平等的梯度更新，In-Batch 机制将 1个正样本和 bs-1个负样本放入同一个 Softmax 分母下竞争概率。模型会对得分越高的困难负样本分配更大的惩罚梯度，而对极易区分的简单负样本的梯度自动衰减。这使得训练高度聚焦于易混淆的边界样本，大幅提升了模型的鉴别能力。

缺点：

- 存在热门物品打压程度过大的问题。因为热门物品本身点击量大，它们出现在各个 Batch 中的概率极高。这就导致模型在训练时，频繁地把热门物品当作负样本进行惩罚，导致它们最终的打分被过度压低
- 存在样本选择偏差的问题。正负样本都来源于点击事件，这就导致没有被点击过的item并没有参与到模型的训练当中（模型从未见过），但是推理时是对所有item都构建embedding，使得训练和推理时样本分布不一致的问题，从而导致召回出现偏差

解决：

- **数学层面的偏差校正（LogQ 校正）**：这是 Google 在双塔论文里提出的经典做法。既然我们知道物品 i 被作为负样本采样的概率 p_i 是热度影响的（被点击的频次，已知），那在最后计算 Softmax 输出的 Logits 时，直接减去这个概率对数，也就是： $s(u, i) = \cos\langle \mathbf{u}, \mathbf{i} \rangle - \log(p_i)$
 - 这个公式是数学推导出来的，具体原因有点复杂，因为负采样会使得softmax结果有点偏差，这里的减法主要是对原始softmax结果的有偏估计（一般不会问那么细节）
 - **个人理解**：因为热门物品目前被打压过度了，对于正样本而言，模型需要提高 $s(u, i)$ 的结果，热度越高， p_i 越高， $-\log(p_i)$ 越接近0，那么模型要提高 $s(u, i)$ ，只能提高 $\cos(u, i)$ 的分数也就是当前样本对的分数；反之热度越低， $-\log(p_i)$ 越大（是个正数），模型要提升 $s(u, i)$ 只需要稍微提升一点 $\cos(u, i)$ ，所以热门物品的分数就被补偿回来了。
- **采用混合负采样**，在所有item库中等权随机采样，因为item具有长尾特性，大部分item都是点击很少或没有点击的，因此等权随机采样有几率把0点击item纳入到负样本中参与训练，从而弥补选择性偏差的问题

5. 排序的正负样本比例是多少？不平衡的解决方法有什么？

答：1:召回数-1。方法有：降采样负样本；调整正负样本对于损失的权重；采用对正负样本比例不太敏感的指标进行评估如（AUC）；采用focal loss这种可以应对不平衡状况的损失函数等。

召回模型

6. 讲一下itemcf是如何计算的？分母和分子是什么？

答：通过在user的行为点击序列中，统计item两两出现的频次计算得到。其中分子为两个item共现次数，分母为两个item总出现次数乘积开根号（余弦相似度）。其中最终分数还通过了位置间隔加权、用户活跃度抑制等优化。

7. 双塔模型的结构

输入和输出是怎么样？ user embedding和item embedding是如何生成的？包括loss是如何设计的？

- **用户塔输入：**用户的静态特征（点击环境）与用户历史行为序列（如最近观看的视频 ID）；
- **Item塔输入：**item侧特征，基础特征或一些统计特征
- **模型结构：**
 - 所有特征经过 embedding 后拼接；
 - 使用多层全连接网络（MLP）生成一个embedding表征；
 - 用户塔输出用户表征向量
 - item塔输出item表征向量
 - 两个向量进行L2归一化后内积，得到的结果进行损失计算
 - 最终输出层是一个 Softmax 层，对同属于一个user的多个内积分数进行激活后计算交叉熵损失（包含1个正样本和多个负样本）。

8. 双塔召回中的热门物品打压好还是不打压好？

热门物品本身天然具备高转化率，过度打压会导致推荐大盘的 CTR 和用户留存出现断崖式下跌，尤其是冷启动和低活用户极其依赖热门内容承接。但是为了提高长尾物品的分发，使得推荐更加个性化而不是一味的追求热门，有需要一定打压，因此需要平衡进行适度打压。

9. 双塔为什么不能交叉？为什么要对生成的embedding归一化？为什么要用余弦相似度？

- 为了满足线上**极致的召回性能要求**。如果User和Item特征在底层交叉，就必须在线为千万级候选物品进行实时的复杂网络计算。双塔结构使得Item Embedding可以离线预先计算并存入向量数据库，线上仅需计算一次User Embedding，再通过高效的检索快速召回。
- 归一化（L2 Normalize）内积计算与余弦相似度计算完全等价。

- 核心原因是余弦相似度能够纯粹地衡量两个向量在语义方向上的一致性，而不受向量模长的干扰。在模型学习中，如果不加限制，模型很可能会通过无限放大热门物品或重度用户 Embedding 的绝对数值，来强行拉高它们与任何物品的点积得分。使用余弦相似度的角度度量，逼迫模型只能去学习用户偏好和物品属性之间真正的深层匹配关系。

10. Faiss中的向量检索用的什么方法构建？

- **做法：** Faiss 在离线阶段，利用 K-Means 聚类算法将海量向量空间划分成 N 个簇，并计算出每个簇的中心点。这就形成了一个倒排表（每个中心点下面挂着属于这个簇的所有向量）。
- **线上检索：** 当一个User向量过来时，Faiss 首先计算 Query 与这 N个簇中心点的距离，挑选出距离最近的n个簇（比如只选最近的 3 个簇）。
- **收益：** 这样一下子就把搜索范围从全局搜索缩小到了被选中的这几个局部簇中，极大地减少了计算量。

11. 召回融合是怎么做的？召回数量是多少？增加召回数量对最终结果有提升吗？提升多少？

- 每个召回选择了100个，然后进行了归一化加权融合后再排序，最终选取了前50个参与后续的排序。
- 考虑效率问题离线实验最初都是基于50个召回来做，确定好相关配置后，有试过100和200，有微弱提升，在线提交的提升比较微弱，都是0.001这种量级的，印象中是0.002~0.003这样

12. 哪个召回算法比较好，为什么？以及召回的迭代思路？

我采用了分阶段、逐步精细化的迭代路径：

阶段一：快速上线尝试（基线方案）

- 使用 **ItemCF** 快速构建召回通道，验证初步可行性；
- 不需要训练，直接根据统计信息

阶段二：用户兴趣建模阶段（**也可以跳过这个**，因为现在有的面试官听到YoutubeDNN也觉得是双塔，但是初始版本是没有item塔的，item embedding是从用户塔输出的embedding到最后一层 Softmax 的线性投影权重矩阵提取出来的，所以在线上serving阶段，也是一种双塔，但是训练时 item属性无法引入）

- 引入 **YoutubeDNN 多分类版本（初始版）**，从历史序列中提取用户兴趣；
- 使用 Softmax 构造多分类任务

阶段三：表达增强与泛化能力提升

- 使用 **DSSM 双塔**，引入丰富特征（item 侧信息如类别、上下文等）；
- 适合无交互行为item的冷启动

模型	优势	局限性	适用场景
ItemCF	简单易实现、无监督、（对点击较少的用户较为友好）	无法泛化，对热门 item 偏好严重，无法处理用户/物品语义特征	数据稀疏场景
YoutubeDNN（多分类版）	可建模复杂用户兴趣，训练效率高，部署简单	无法引入 item 特征，推荐多样性较差，不能处理冷启动 item	用户活跃、历史行为丰富、规模大
DSSM 双塔	支持引入丰富的 item/user 特征，向量化召回高效，支持近似检索（ANN）	训练难度更大，特征工程复杂，模型不稳定时可能退化	成熟业务阶段，支持冷启动/多特征时表现最佳

13. 多路召回怎么融合？权重怎么设置？某一路偏高怎么办？

- 按照item被召回的通道数优先排序，然后归一化每路召回分数并按照权重加和，按照融合分进一步排序
- 权重是DSSM:ItemCF=0.55:0.45，枚举尝试得到的效果最好的权重
- 已经设置按照通道数优先排序，某一路偏高的影响已经被削弱。其次，某一路分数偏高本来也是符合预期的。因为我们引入多路召回的本质是为了覆盖不同的视角，每路算法的优化目标和依赖的特征空间都不一样。所以同一个Item，在不同的召回通道里表现出的分数有高有低是非常正常的，这也是多路融合用来做优势互补的意义。


精排模型

14. 描述一下DIN结构，描述一下DIN中的target attention

- DIN 的核心结构如下：
1. 输入Embedding层：
 - 序列特征item embedding 列表和候选item embedding和其他特征拼接后的embedding
 2. Target Attention Layer（兴趣激活机制）：
 - 针对用户的历史行为序列，通过 attention 激活单元为每个历史 序列item 分配一个与当前候选 item 相关的权重；
 - 得到一个加权汇总后的兴趣表示，用于表示用户对该候选 item 的兴趣强度。
 3. MLP 层：将加权兴趣表示与其他特征拼接，输入多层感知机，输出最终点击概率。
 4. 损失函数：BCE损失函数（二元交叉熵）

Target Attention Layer:

该模块用于对用户的历史行为（Last N items）与当前候选 item 进行相关性建模。具体做法是：将每个历史 item 与候选 item 分别进行**向量差（element-wise subtraction）**和**向量乘积（element-wise product）**操作，并将这两者与原始的历史 item 和候选 item 一起拼接，形成一个融合特征向量。该向量随后被输入至一个全连接神经网络，用于学习每个历史行为与候选 item 之间的相关性权重，作为注意力权重对历史兴趣加权融合。



15. DIN的优势在哪？相比于pooling MLP好在哪？

DIN主要用于序列建模，可以捕捉用户兴趣与当前候选物品之间的关系，激活局部兴趣。它利用**target-aware attention** 机制，根据候选 item 动态激活用户历史行为序列中与其更相关的行为，使得这些行为在聚合过程中的权重更大。这样可以有效捕捉**用户对当前 item 的局部兴趣偏好**，避免了静态 pooling 对**用户差异化兴趣的抹平**。

评估指标与优化迭代

16. MRR指标是什么？

答：所有正样本的排名的倒数平均值
其对应的数学公式如下：

$$\text{MRR} = \frac{1}{N} \sum_{i=1}^N \frac{1}{\text{rank}_i}$$

公式中各变量的含义：

- N ：正样本（或查询请求）的总数量。
- rank_i ：第 i 个正样本在模型给出的排序列表中的确切名次（排名位次）。
- $\frac{1}{\text{rank}_i}$ ：即第 i 个正样本排名的倒数。

17. 精排中还有哪些指标可以衡量效果？为什么选用？介绍一下。

见 [搜推相关基础知识/指标相关.pdf](#)

场景题

18. 对于长尾或者重来没有点击行为的item，目前的方法能够召回吗？如何做冷启动？

- 协同过滤是无法召回的，因为 CF 强依赖历史交互行为。但我双塔模型为每个item都构建了embedding都提供了召回的机会。
- 除此之外，还可以基于用户的内容构建embedding，通过内容embedding相似度进行召回。
- 根据创作者推流，item冷（新），但是作者不冷，可以推荐至经常点击该作者作品的用户
- 流量扶持

19. 如果是完全没有点击过的用户，你要怎么推荐？有什么思路吗？

- 如果毫无信息流，只能利用系统获取的粗略特征（比如地域、年龄段、设备型号、下载渠道等），直接使用基于这群人的**全局热门内容**或者高点击率的“试探性”内容进行推荐，保证新用户的第一次视觉感知不差。
- 双塔仅根据用户的基础特征也能生成embedding，可以到item向量库中召回一批热度高、普适性好的item作为初次推荐
- 一些其他场景在新用户创建时会选择兴趣，可以基于这些兴趣卡片进行相应推荐。