


离线评估与在线提交流程

❤ 本文档描述项目从**数据构建**、**离线评估**到最终**在线提交**的完整实验流程。离线评估用于验证召回和排序策略的效果，在线提交则基于确定的策略对测试集用户生成最终推荐结果。

一、整体流程概览



二、离线评估阶段

🍰 离线评估阶段的核心目标是**模拟真实预测场景**，通过留出每个用户的最后一次点击作为 Ground Truth，评估召回和排序策略的效果。

2.1 数据准备与划分

1. **合并全量数据**：将训练集（`train_click_log.csv`）和测试集（`testA_click_log.csv`）合并为全量数据 `all_data`。
2. **过滤短序列用户**：剔除点击序列长度小于2的用户（只有1次点击的用户无法拆分出训练和验证样本）。
3. **构建训练历史和验证标签**：
 - `trn_hist_df`：每个用户的除最后一次点击外的所有点击序列，用于构建召回训练数据和相似矩阵
 - `trn_last_df`：每个用户的最后一次点击，作为离线评估的Ground Truth标签。

代码块

```
1  用户原始点击序列: [c1, c2, c3, c4]
2      ↓
3  trn_hist_df: [c1, c2, c3]    ← 用于训练和召回
4  trn_last_df: [c4]           ← 用于评估 (Ground Truth)
```

2.2 多路召回训练与评估

2.2.1 ItemCF 协同过滤召回

1. **构建相似矩阵**：基于 `trn_hist_df`（已剔除最后一次点击）中所有用户的点击序列计算Item-Item共现相似度矩阵。
2. **召回**：对每个用户，基于其 `trn_hist_df` 中点击序列，从相似矩阵中查找Top-K相似Item，过滤掉用户已点击过的Item，按加权分数排序取Top-50。
3. **打标签**：将召回的每个候选Item与 `trn_last_df` 对比，匹配则 `label=1`（正样本），否则 `label=0`。
4. **评估**：计算HitRate@K和MRR@K（K=5/10/20/40/50），召回阶段主要看HR@50。

2.2.2 DSSM 双塔召回

1. **构建滑动窗口训练数据**：在 `trn_hist_df`（已剔除最后一次点击）上使用滑动窗口构建训练样本。**注意**：滑动窗口是在已剔除最后一次点击的序列上进行的，不是原始完整序列。以用户点击序列 `[c1, c2, c3]`（来自 `trn_hist_df`）为例：

训练样本	用户历史序列（特征）	目标点击（Label）
样本1	<code>[c1]</code>	<code>c2</code>
样本2	<code>[c1, c2]</code>	<code>c3</code>

2. **向量召回**：通过FAISS IndexFlatIP（内积索引）在全量Item Embedding中检索Top-200近邻，**过滤已点击Item**后保留Top-100。（这里有做过数据分析，99%的用户是不存在重复点击的情况的，可以去掉）
3. **打标签与评估**：同ItemCF，将召回结果与 `trn_last_df` 对比打标签，计算HitRate和MRR。**主要关注HitRate**，因为在召回阶段核心目标是覆盖率而非排序精度。

2.3 排序模型训练

1. **训练数据筛选**：仅保留至少有1个正样本（`label=1`）的用户参与排序训练。原因是：
- 若某用户的50个召回候选中包含了真实点击的Item，则1个正样本 + 49个负样本，可以训练。
 - 若某用户的真实点击未被召回，则50个全是负样本，对模型训练无意义（噪声），应剔除。
2. **模型训练**：使用GroupKFold交叉验证（按`user_id`分组，防止同一用户数据跨折泄露），K为5折
3. **离线评估**：利用Out-of-Fold预测计算MRR@5等指标评估排序效果。（也就是验证集那一折的排序效果，5折就是5个验证集，拼起来就是全集）

2.4 离线评估指标汇总

阶段	指标	说明
召回	HitRate@K	

		主要指标，衡量真实点击被召回的比例
召回	MRR@K	辅助指标，衡量真实点击在召回列表中的排名
排序	MRR@5	核心指标，衡量最终Top-5推荐的排序质量

三、在线提交阶段

 在离线评估确定策略和超参数后，进入在线提交阶段，为测试集用户（`user_id ∈ [200000, 249999]`）生成最终推荐结果。

3.1 与离线评估的关键差异

维度	离线评估	在线提交
数据范围	全量数据（序列长度大于2），剔除最后一次点击	全量数据（序列长度大于2）， 保留所有点击
目标用户	全部用户（序列长度大于2）	仅测试集用户（ <code>user_id ∈ [200000, 249999]</code> ）
召回标签	有（ <code>label=0/1</code> ）	无
ItemCF相似矩阵	基于 <code>trn_hist_df</code> （不含最后一次点击）	基于全量数据（含最后一次点击）重新构建
DSSM模型	训练并生成Embedding	基于全量数据重新训练模型 、生成测试用户Embedding进行召回
排序模型	K-Fold交叉验证训练	不重新训练 ，使用K-Fold各折模型直接推理并平均

3.2 召回阶段

ItemCF

- 使用全量数据 `df_filter` （包含所有点击，含最后一次）**重新构建相似矩阵**。
- 基于新的相似矩阵，对测试集用户进行召回。

DSSM

- 使用全量数据 `df_filter` （包含所有点击，含最后一次），基于滑动窗口构建训练集，**重新训练模型**
 - 为测试集用户生成Embedding，重新构建FAISS索引，进行向量召回，召回测试集用户的候选Item
- 实际上（代码）我是没有重新训练的，当时是考虑了需要修改代码逻辑比较麻烦没有往下做，后面细想后应该要尽可能利用已有的数据

3.3 召回融合

对测试集用户的多路召回结果进行与离线评估相同的加权投票融合，过滤后为每个测试集用户生成50个召回结果

3.4 排序

- 排序模型在K-Fold训练过程中，**每一折同时对测试集用户进行预测**，最终将各折预测结果取平均，**排序模型无需额外重新训练**。
- 对测试集用户的候选Item按排序分数降序排列，取Top-5生成提交文件。

3.5 提交文件格式

代码块

```
1 user_id, article_1, article_2, article_3, article_4, article_5
2 200000, 123456, 234567, 345678, 456789, 567890
3 ...
```

四、涨点改进



这些导致涨点的优化有些还是太普通，不值一提，除非面试官问，给大家参考，也是我的印象涨点幅度

召回（离线评估）

1. itemcf加入位置间隔权重、引入用户活跃度抑制和直接用近两篇点击文章召回，其中用近两篇点击文章召回的优化上涨最明显3%左右，进一步证明了新闻场景的短期时效性。总共能够上涨5%左右的hitrate@50（绝对值67.99%）
2. 最开始DSSM是使用基于流行度的负采样，效果比较差，改为Batch_size后好很多（可以不提）
3. DSSM处理序列特征时，将融合策略由直接平均改为按照点击位置加权，上涨3%hitrate@50（绝对值71.74%）
4. 多路召回融合后上涨2%hitrate@50（绝对值0.7370%）

精排

因为排序是滤除了没有被召回的样本，所以离线评估MRR会虚高，不过只看相对值，影响不大

1. 将连续特征由归一化直接拼接修改为先等频分桶转换成ID特征统一处理，MRR@5涨点0.04-0.05（绝对值0.36）
2. 将两路召回各自分数作为特征引入后，涨点0.02MRR@5（绝对值0.38）
3. DIN的效果好于DCN（线上MRR效果，就好那么一点点，不超过0.01，绝对值0.294）
4. 把召回数量从50->100->200，也有微弱提升，0.002-0.003左右的提升（在线MRR效果）
5. 最终最高达到0.2992