

阿里天池新闻推荐

项目介绍

本项目是一个**新闻推荐任务**，核心目标是通过用户历史点击行为和新闻文章特征，从候选文章库中筛选出用户最可能点击的Top5新闻，**生成个性化Top5推荐列表**。推荐效果通过**MRR (Mean Reciprocal Rank)** 指标量化评估，该指标根据用户真实的下一次点击新闻在推荐列表中的排名计算得分，最终以所有测试样本得分的均值衡量预测准确性。

项目链接：<https://tianchi.aliyun.com/competition/entrance/531842>

代码链接：<https://github.com/Haiwangxing-ggdxz/XWTJ>

数据集

初始数据集主要有：

1. 用户的历史行为交互数据；用户ID，点击的文章ID，点击的时间，用户点击的环境等上下文信息
2. 所有文章的属性：包括文章的ID、字数、类别ID、创建时间以及embedding向量。

具体为：

代码块

```
1  articles_emb:
2      新闻文章embedding向量表示 (article_id, emb0,...,emb249)
3  articles.csv:
4      新闻文章信息数据表 (article_id, category_id, created_at_ts, words_count)
5  train_click_log:
6      训练集用户点击日志 (user_id, click_article_id, click_timestamp,
7      click_environment,
8      click_deviceGroup, click_os, click_country, click_region,
9      click_referrer_type)
10 testA_click_log.csv:
11     测试集用户点击日志 (同训练用户点击日志)
```

Field	Description
user_id	用户id
click_article_id	点击文章id
click_timestamp	点击时间戳
click_environment	点击环境
click_deviceGroup	点击设备组
click_os	点击操作系统
click_country	点击城市
click_region	点击地区
click_referrer_type	点击来源类型
article_id	文章id，与click_article_id相对应
category_id	文章类型id
created_at_ts	文章创建时间戳
words_count	文章字数
emb_1,emb_2,...,emb_249	文章embedding向量表示

一些数据分析

面试被问住了，可以看看是否可以从以下数据分析结果回答

文章

代码块

```
1  被点击次数小于各阈值(threshold=1~10)的文章占比：
2  threshold  percentage
3          1      90.28
4          2      95.43
5          3      96.44
6          4      96.91
7          5      97.23
8          6      97.48
9          7      97.66
10         8      97.81
11         9      97.95
12        10      98.06
```

用户

- 1 点击次数小于 1 的用户占比为：0.00%
- 2 点击次数小于 2 的用户占比为：3.81%
- 3 点击次数小于 5 的用户占比为：58.68%
- 4 点击次数小于 10 的用户占比为：81.67%
- 5 点击次数小于 20 的用户占比为：94.28%
- 6 点击次数小于 30 的用户占比为：97.66%